

RAG（检索增强生成） — 技术概述

RAG 全称 Retrieval-Augmented Generation（检索增强生成），是一种将大语言模型（LLM）与外部知识库相结合的技术，能生成更准确、更新及时的答案。

核心流程 —— 三步走：

第一步

检索（Retrieval）：当用户提问时，系统在向量数据库中搜索最相关的文档片段。这一步使用 Embedding 模型将文本转换为高维向量，并通过余弦相似度计算语义距离。

第二步 增强（Augmentation）：将检索到的文档片段作为上下文插入 Prompt 中。这就是「增强」的含义——给 LLM 提供它从未训练过的外部知识。

第三步 生成（Generation）：LLM 基于提供的上下文生成答案，而非依赖其参数化记忆。这能显著减少虚假生成（幻觉）。

RAG 的三大核心优势：

- 1. 实时更新 —— 只需重新索引文档，无需重新训练整个模型。
- 2. 来源可追溯 —— 每个答案都可以引用具体的文档出处。
- 3. 数据安全 —— 知识库在本地运行，无需把敏感数据发给 LLM 提供商。

RAG 架构组件生态：

- 文档加载器：TextLoader、PyPDFLoader、CSVLoader、UnstructuredLoader
- 文本分割器：RecursiveCharacterTextSplitter、SemanticChunker

- Embedding 模型: text-embedding-3、text-embedding-v3、Cohere
- 向量数据库: ChromaDB、FAISS、Pinecone、Weaviate、Milvus
- 大语言模型: GPT-4o、DeepSeek、Qwen、Claude、Gemini

高级 RAG 技术一览:

- HyDE (假设文档嵌入): 先生成一个假设性答案, 再用该答案去检索——提升召回率。
- Multi-Query (多查询): 生成多个查询变体, 分别检索后合并结果。
- Reranker (重排序): 用二阶段排序模型对初步检索结果二次排序。
- Self-RAG (自反思检索): LLM 自行判断每一步是否需要检索。
- Agentic RAG (智能体 RAG): 用 LangGraph 构建多步推理智能体, 自主决策检索策略、工具调用和响应生成。